

Lekcja 13b - Spark na Databricks

2026-09-10

Data Engineering Course

Spark na Databricks

To jest most między lokalnym PySpark a platformowym runem w Databricks.

■ Po co osobna lekcja

Masz już:

- Spark foundations,
- Delta basics,
- Spark internals.

Teraz potrzebujesz zobaczyć:

jak ten sam Spark code żyje w Databricks workflow

■ Najprostszy flow

```
workspace  
-> compute  
-> notebook  
-> read / transform  
-> Delta table  
-> job
```

Zapamiętaj ten lanchuch.

■ Problem bez tej lekcji

Bez tego łatwo pomieszać:

- kod,
- compute,
- storage,
- checkpoint,
- scheduler.

I wtedy myśleć, że Databricks to tylko "notebook w chmurze".

■ Compute first

Pierwsze pytanie nie brzmi:

Jakie query napisze?

Pierwsze pytanie brzmi:

Na czym ten kod sie wykona?

■ Notebook role

Notebook służy do:

- developmentu,
- eksploracji,
- pierwszego ETL walkthrough,
- debugowania.

Notebook sam z siebie nie jest jeszcze operacyjnym pipeline.

■ Delta output

Outputem nie jest tylko DataFrame na ekranie. Outputem jest tabela Delta.

To znaczy:

wynik zyje po zakonczeniu notebooka

■ Auto Loader i checkpoint

Tutorial Databricks pokazuje:

```
new files -> Auto Loader -> checkpoint -> Delta
```

Checkpoint odpowiada na pytanie:

```
Co juz przetworzylem?
```

■ Job

Job daje:

- schedule,
- retries,
- monitoring,
- history runow,
- ownership.

Czyli:

```
job > manual Run notebook
```

■ Development vs production

```
manual notebook run = development  
scheduled notebook task = operacyjny pipeline
```

To jest granica, która musisz umieć nazwać.

■ Co jest developerskie, a co platformowe

Developerskie:

- Spark transformations,
- schema,
- data logic.

Platformowe:

- compute,
- access,
- storage binding,
- jobs,
- monitoring.

Glowny tutorial:

1. Databricks tutorial: Build an ETL pipeline with Apache Spark on the Databricks platform
<https://docs.databricks.com/aws/en/getting-started/etl-quick-start>

■ Co oddajesz po lekcji

```
homework/lesson_13b/  
  01_workflow_map.md  
  02_notebook_to_job.md  
  03_delta_checkpoint_notes.md  
  04_tutorial_walkthrough.md  
  05_interview_answers.md
```

■ Closing check

Powiedz na głos:

```
Spark w Databricks to workflow:  
compute, notebook, Delta output, checkpoint i job.
```